

Trabajo Final Integrador: Minería de datos I

1. Contexto y Objetivos

Contexto y Objetivos

Propósito del Proyecto Integrador

El Proyecto Integrador consiste en desarrollar un análisis de datos reproducible y comunicable a partir del dataset provisto por la cátedra. El trabajo deberá evidenciar un proceso ordenado de exploración, preparación, análisis, interpretación y comunicación de resultados.

Objetivo general

Aplicar los contenidos de Minería de Datos 1 para construir un proyecto de análisis de datos con decisiones justificadas, trazabilidad del proceso y comunicación clara de los resultados.

Objetivos del proyecto

- Comprender la estructura y la calidad inicial del dataset mediante una inspección documentada.
- Preparar los datos a partir de decisiones justificadas con evidencia observada.
- Realizar análisis univariado, bivariado y multivariado con interpretaciones vinculadas a los objetivos definidos por el grupo.
- Aplicar escalamiento y reducción de dimensionalidad mediante PCA, documentando las decisiones y resultados obtenidos.
- Comunicar resultados mediante una aplicación pública en Streamlit y un informe final breve.
- Construir un repositorio reproducible que permita revisar el proceso completo, desde los datos originales hasta las conclusiones.

Alcance

El proyecto incluye inspección inicial, calidad de datos, preparación, análisis exploratorio, visualización, escalamiento y PCA. No es un proyecto de modelado predictivo ni de despliegue de modelos.

Criterio central de trabajo

No se evaluará únicamente la aplicación de funciones, la cantidad de código o la cantidad de gráficos. Se evaluarán principalmente las decisiones justificadas con evidencia, la trazabilidad del proceso, la coherencia entre etapas y la claridad para comunicar resultados.

Las decisiones deben surgir de la inspección y de la evidencia obtenida durante el proyecto, no de la aplicación automática de técnicas.

2. Entregables del proyecto y requisitos de entrega

Entregables del proyecto y requisitos de entrega

Modalidad de trabajo

- Trabajo grupal de 2 integrantes.
- Se admite un grupo de 3 integrantes solo con autorización excepcional.
- Cada grupo deberá presentar un repositorio público de GitHub.
- La estructura obligatoria del repositorio no debe modificarse.

Estructura obligatoria del repositorio

```
PI_Mineria_Datos_1/
├── README.md
├── requirements.txt
├── data/
│   ├── raw/
│   └── processed/
├── notebooks/
│   ├── 01_inspeccion_inicial.ipynb
│   ├── 02_calidad_y_limpieza.ipynb
│   ├── 03_edo.ipynb
│   ├── 04_pca.ipynb
│   └── 05_conclusiones.ipynb
├── app/
│   ├── Home.py
│   └── pages/
│       ├── 01_Dataset.py
│       ├── 02_EDA.py
│       ├── 03_PCA.py
│       └── 04_Conclusiones.py
├── reports/
│   └── informe_final.pdf
├── logs/
│   └── pipeline_log.csv
```

Propósito de cada componente

- data/raw/ debe contener el dataset original sin modificaciones.
- data/processed/ debe contener el dataset final utilizado durante el análisis.
- notebooks/ debe contener el desarrollo ordenado de las etapas del proyecto.
- app/ debe contener la aplicación pública desarrollada en Streamlit.
- reports/ debe contener el informe final en PDF.
- logs/ debe contener el registro de las transformaciones realizadas durante el proceso ETL.
- README.md debe documentar técnicamente el proyecto mediante texto y enlaces.
- requirements.txt debe declarar las dependencias necesarias para ejecutar el proyecto.

README obligatorio

El archivo README.md debe incluir las siguientes secciones:

- Información general.
- Objetivo del proyecto.
- Dataset.
- Estructura del repositorio.
- Preparación y calidad de datos.
- Resumen del análisis exploratorio.
- Reducción de dimensionalidad.
- Visualización interactiva.
- Cómo ejecutar localmente.
- Conclusiones.

Debe respetar los siguientes límites:

- Objetivo del proyecto: máximo 10 líneas.
- Dataset: máximo 15 líneas.
- Preparación y calidad de datos: máximo 20 líneas.
- Resumen del análisis exploratorio: máximo 20 líneas.
- Reducción de dimensionalidad: máximo 15 líneas.
- Conclusiones: máximo 15 líneas.

El README debe contener solo texto y enlaces. No se permiten imágenes, capturas ni gráficos. No debe duplicar resultados ya presentados en Streamlit o en el informe. Debe referenciar notebooks, informe, log ETL y aplicación cuando corresponda, incluir instrucciones breves para ejecutar la aplicación localmente e incorporar el enlace público a Streamlit Cloud.

Aplicación Streamlit obligatoria

```
app/
├── Home.py
└── pages/
    ├── 01_Dataset.py
    ├── 02_EDA.py
    ├── 03_PCA.py
    └── 04_Conclusiones.py
```

- La aplicación debe estar desplegada públicamente en Streamlit Cloud.
- Debe incluir un enlace al repositorio público de GitHub.
- Debe comunicar resultados para público general y no reemplaza la evidencia técnica del repositorio.
- El diseño, los filtros, la interacción y la narrativa visual quedan a criterio del grupo.

Contenido mínimo de la aplicación:

- Home: título del proyecto, integrantes, comisión, fecha, contexto breve y enlace al repositorio GitHub.
- Dataset: descripción general, resumen breve de calidad, vista previa simple y mención breve de las transformaciones principales.
- EDA: 2 visualizaciones univariadas, 2 visualizaciones bivariadas, 1 visualización multivariada e interpretación obligatoria para cada resultado. Total exacto: 5 visualizaciones.
- PCA: variables utilizadas, escalamiento aplicado, varianza explicada, interpretación y máximo 2 visualizaciones.
- Conclusiones: hallazgos, limitaciones y próximos pasos.

Informe final obligatorio

El archivo `reports/informe_final.pdf` debe entregarse en formato PDF, con una extensión máxima de 2 páginas. Puede incluir solo texto, tablas pequeñas y enlaces. No debe incluir código ni repetir gráficos ya presentes en Streamlit.

Debe incluir:

- Contexto y objetivo.
- Dataset y calidad inicial.
- Decisiones de limpieza y preparación.
- Hallazgos del análisis exploratorio.
- PCA.
- Conclusiones y limitaciones.
- Enlaces al repositorio y a Streamlit.

Log ETL obligatorio

El archivo logs/pipeline_log.csv debe registrar cada transformación relevante con las siguientes columnas mínimas:

Paso | Descripción | Filas | Nulos | Retención (%)

El registro debe permitir comparar el estado inicial y final del dataset.

Requisitos de reproducibilidad

- Dataset original preservado en data/raw/.
- Dataset procesado disponible en data/processed/.
- Dependencias declaradas en requirements.txt.
- Notebooks ejecutables.
- Enlaces públicos funcionales al repositorio y a Streamlit.
- Repositorio sin credenciales, claves ni archivos sensibles.
- Repositorio sin entornos virtuales.
- Repositorio sin archivos innecesarios.

Checklist de entrega

- Repositorio público con la estructura obligatoria completa.
- Dataset original y dataset procesado disponibles en las carpetas correspondientes.
- README completo, dentro de los límites indicados y con enlaces funcionales.
- Notebooks ordenados y ejecutables.
- Aplicación pública en Streamlit Cloud con enlace al repositorio.
- Informe final en reports/informe_final.pdf.
- Log ETL disponible en logs/pipeline_log.csv.

3. Guía para el desarrollo del proyecto integrador

Guía para el desarrollo del proyecto integrador

Propósito de la guía

Esta guía organiza el proceso de trabajo y define dónde debe evidenciarse cada etapa. El objetivo es construir un análisis coherente, justificable y reproducible, sin reemplazar las decisiones que correspondan al grupo.

Antes de comenzar

- Revisen el dataset y la documentación disponible.
- Comprendan qué representa cada registro y cuál es el alcance de la información disponible.
- Identifiquen variables, tipos de datos y aspectos que requieran revisión posterior.
- Formulen preguntas de análisis concretas a partir de la inspección inicial.
- Cada pregunta debe poder responderse con evidencia obtenida durante el proyecto.
- Inspección inicial

La etapa debe desarrollarse en 01_inspeccion_inicial.ipynb. Presenten la estructura general, dimensiones, tipos de datos, valores faltantes, duplicados y observaciones iniciales. En esta etapa no se espera tomar decisiones definitivas, sino reunir evidencia para orientar las etapas posteriores.

Calidad, limpieza y preparación

La etapa debe desarrollarse en 02_calidad_y_limpieza.ipynb. Para cada decisión de preparación, indiquen la evidencia que la motivó, la acción aplicada y el impacto observado en el dataset.

- Preserven el dataset original sin modificaciones en data/raw/.
- Guarden el resultado final utilizado en data/processed/.
- Registren cada transformación relevante en logs/pipeline_log.csv.
- Expliquen la decisión tomada, su justificación y el efecto observado luego de aplicarla.

No presenten una decisión de preparación sin evidencia. Por ejemplo, no indiquen solamente que los datos se limpiaron porque estaban mal; expliquen qué se observó, qué acción se aplicó y qué impacto tuvo en el dataset.

Análisis exploratorio

La etapa debe desarrollarse en 03_eda.ipynb. Debe incluir análisis univariado, bivariado y multivariado. Cada visualización debe incluir una interpretación vinculada con una pregunta u objetivo definido por el grupo.

Interpretar no consiste en describir solamente colores, ejes o valores visibles. Interpretar consiste en explicar qué muestra el resultado en relación con una pregunta u objetivo del proyecto y qué evidencia aporta al análisis.

Escalamiento y PCA

La etapa debe desarrollarse en 04_pca.ipynb. Documenten las variables utilizadas, el escalamiento aplicado, la varianza explicada y la interpretación de las componentes obtenidas. PCA no debe presentarse solo como código ejecutado: debe incluir una explicación clara del propósito y del resultado dentro del análisis realizado.

Conclusiones

Las conclusiones deben desarrollarse en 05_conclusiones.ipynb y mantenerse coherentes con el informe final y la aplicación Streamlit. Deben responder a los objetivos y preguntas definidos por el grupo, diferenciando evidencia, interpretación y conclusión.

Limitaciones y mejoras futuras

Las limitaciones son aspectos del dataset, del proceso o del alcance que restringen lo que puede concluirse. Las mejoras futuras son acciones posibles para ampliar, fortalecer o profundizar el proyecto en una etapa posterior.

Ejemplo de redacción de limitación: “El alcance de las conclusiones se encuentra condicionado por la información disponible y por las decisiones documentadas durante el proceso.”

Ejemplo de redacción de mejora futura: “Una mejora futura podría consistir en incorporar información adicional que permita ampliar el alcance del análisis.”

No presenten una limitación como si fuera un hallazgo.

Uso de IA

- La IA puede utilizarse como apoyo para comprender conceptos, revisar código, organizar el trabajo o mejorar la redacción.
- Cada integrante debe poder explicar y defender las decisiones, resultados y conclusiones presentadas.
- No deleguen en IA la comprensión del dataset ni la justificación de decisiones.
- Todo contenido incorporado al proyecto debe ser comprendido, revisado y validado por el grupo.

Errores frecuentes a evitar

- Modificar el dataset original.
- Aplicar limpieza sin evidencia.
- Eliminar o imputar valores automáticamente.
- Mostrar gráficos sin interpretación.
- Ejecutar PCA sin explicar variables, escalamiento o resultado.
- Duplicar contenido entre README, informe y Streamlit.
- Subir credenciales, entornos virtuales o archivos innecesarios.
- Entregar enlaces públicos que no funcionan.

4. Rúbrica

Rúbrica

- Cumplimiento de estructura, trazabilidad y claridad documental — 10 puntos.
- Inspección inicial y comprensión del dataset — 10 puntos.
- Calidad, limpieza y preparación de datos — 20 puntos.
- Análisis exploratorio e interpretación — 25 puntos.
- Escalamiento y PCA — 10 puntos.
- Comunicación de resultados — 10 puntos.
- Defensa oral y dominio conceptual — 15 puntos.

Puntaje total: 100 puntos.

Cada integrante responderá una pregunta individual sobre cualquier etapa, decisión o resultado del proyecto.